



ECOLE CENTRALE DE NANTES

PROJET METHODES BAYÉSIENNES ET MODÈLES HIÉRARCHIQUES

---

## Seeds: Random effect logistic regression

---

*Auteurs:*

Paul Trincklin  
Jiacheng Fu  
Enzo Mori  
Grégory Perret

*Encadrant:*

Mathieu Ribatet

March 24, 2022

# 1 Problématique

L'objectif de ce projet est de modéliser la capacité de germination de deux types de graines (O. aegyptiaco 75 et O. aegyptiaco 73) pour deux variétés différentes (haricot et concombre).

Pour cela on étudie 21 assiettes dans lesquelles ont été planté ces différents types de graines.

On note  $n_i$  le nombre total de graines plantées dans la  $i$ ème assiette,  $r_i$  le nombre de graines ayant germées dans la  $i$ ème assiette, et  $p_i$  la probabilité de germination d'une graine dans la  $i$ ème assiette.

Nous disposons du jeu de données suivant :

INSERER TABLEAU JEUX DE DONNEES

On utilise le modèle suivant :

$$r_i \sim \text{Bin}(p_i, n_i)$$

$$\text{avec } \text{logit}(p_i) = \alpha_0 + \alpha_1 x_{1i} + \alpha_2 x_{2i} + \alpha_{12} x_{1i} x_{2i} + bi$$

$$\text{et } bi \sim N(0, \tau) \text{ où } \tau = \frac{1}{\sigma^2}$$

$x_{1i}$  indique le type de graine (0 pour O. aegyptiaco 75 et 1 pour O. aegyptiaco 73) et  $x_{2i}$  indique la variété (0 pour haricot, 1 pour concombre) dans la  $i$ ème assiette.

# 2 Modélisation mathématique

Les lois a priori de nos différents paramètres sont données:  $\alpha_0 \sim N(0, 10^6)$ ,  $\alpha_1 \sim N(0, 10^6)$ ,  $\alpha_2 \sim N(0, 10^6)$ ,  $\alpha_{12} \sim N(0, 10^6)$ ,  $\sigma^2 \sim \text{InverseGamma}(10^{-3}, 10^{-3})$

On calcule les lois à posteriori pour les différents paramètres pour notre algorithme MCMC associé à un échantillonneur de Gibbs:

(remarque: ici on ne passe pas à l'échelle log, mais ceci est fait dans notre code afin d'améliorer les calculs)

$$\begin{aligned} \pi(b_i \mid \dots) &\propto \pi(b_i \mid \sigma^2) \times \pi(r_i \mid \dots) \\ &\propto e^{-\frac{b_i^2}{2\sigma^2}} \times (p_i)^{r_i} \times (1 - p_i)^{n_i - r_i} \end{aligned}$$

$$\begin{aligned} \pi(\alpha_0 \mid \dots) &\propto \pi(\alpha_0) \times \prod_{i=1}^N \pi(r_i \mid \dots) \\ &\propto e^{-\frac{\alpha_0^2}{2 \times 10^6}} \times \prod_{i=1}^N [(p_i)^{r_i} \times (1 - p_i)^{n_i - r_i}] \end{aligned}$$

$$\begin{aligned} \pi(\alpha_1 \mid \dots) &\propto \pi(\alpha_1) \times \prod_{i=1}^N \pi(r_i \mid \dots) \\ &\propto e^{-\frac{\alpha_1^2}{2 \times 10^6}} \times \prod_{i=1}^N [(p_i)^{r_i} \times (1 - p_i)^{n_i - r_i}] \end{aligned}$$

$$\begin{aligned}
\pi(\alpha_2 \mid \dots) &\propto \pi(\alpha_2) \times \prod_{i=1}^N \pi(r_i \mid \dots) \\
&\propto e^{-\frac{\alpha_2^2}{2 \times 10^6}} \times \prod_{i=1}^N [(p_i)^{r_i} \times (1 - p_i)^{n_i - r_i}] \\
\pi(\alpha_{12} \mid \dots) &\propto \pi(\alpha_{12}) \times \prod_{i=1}^N \pi(r_i \mid \dots) \\
&\propto e^{-\frac{\alpha_{12}^2}{2 \times 10^6}} \times \prod_{i=1}^N [(p_i)^{r_i} \times (1 - p_i)^{n_i - r_i}] \\
\pi(\sigma^2 \mid \dots) &\propto \pi(\sigma^2) \times \prod_{i=1}^N \pi(b_i \mid \sigma^2) \\
&\propto (\sigma^2)^{(-0.001-1)} e^{-\frac{0.001}{\sigma^2}} \times \left(\frac{1}{\sigma}\right)^N e^{-\frac{\sum_{i=1}^N b_i^2}{2\sigma^2}} \\
&\propto \text{InverseGamma}(0.001 + \frac{N}{2}, 0.001 + \frac{\sum_{i=1}^N b_i^2}{2})
\end{aligned}$$

où  $p_i = \text{sigmoid}(\alpha_0 + \alpha_1 x_{1i} + \alpha_2 x_{2i} + \alpha_{12} x_{1i} x_{2i} + b_i)$

### 3 Résultat obtenus et analyse

Vérifions l'allure des chaines de Markov obtenues:

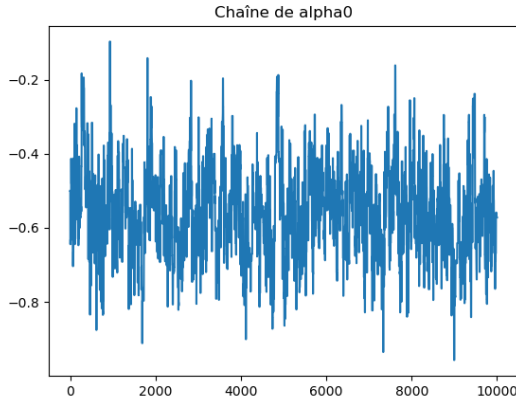


Figure 1: Chaîne de Markov de  $\alpha_0$




Figure 2: Chaîne de Markov de  $\sigma$

Nous obtenons les résultats suivants:

Résultats					
	$\alpha_0$	$\alpha_1$	$\alpha_2$	$\alpha_1 2$	$\sigma$
Moyenne	-0,558	0,144	1,327	-0,789	0,01
Variance	0,017	0,049	0,032	0,09	$2,7 \cdot 10^{-6}$

Nous obtenons des résultats similaires à ceux attendus, excepté pour  $\alpha_1$  et  $\sigma$ .

Interpretons les différents coefficients trouvés afin de voir l'influence de chaque graine sur la probabilité de germer.

En accord avec le modèle choisi, la probabilité de germer est donnée ainsi pour chaque type de graine et chaque variété:

-graine de type O. aegyptiaco 75 , haricot :  $p = \text{sigmoide}(\alpha_0) = \text{sigmoide}(-0,558) = 0,361$

-graine de type O. aegyptiaco 75 , concombre :  $p = \text{sigmoide}(\alpha_0 + \alpha_2) = \text{sigmoide}(-0,558 + 1,327) = \text{sigmoide}(0,769) = 0,682$

-graine de type O. aegyptiaco 73 , haricot :  $p = \text{sigmoide}(\alpha_0 + \alpha_1) = \text{sigmoide}(-0,558 + 0,144) = \text{sigmoide}(-0,414) = 0,399$

-graine de type O. aegyptiaco 73 , concombre :  $p = \text{sigmoide}(\alpha_0 + \alpha_1 + \alpha_2 + \alpha_{1,2}) = \text{sigmoide}(-0,558 + 0,144 + 1,327 - 0,789) = \text{sigmoide}(0,124) = 0,532$

Probabilité de germination		
	seed O. aegyptiaco 75	O. aegyptiaco 75
Haricot	0,361	0,399
Concombre	0,682	0,532

On voit ainsi que pour les concombres, il est préférable de choisir des graines de type O. aegyptiaco 75 puisque la probabilité de germer est supérieure.

Au contraire, pour les haricots, il vaut mieux planter des graines de type O. aegyptiaco 73 qui présente une plus grande probabilité de germination.

Pour les deux types de graines, les concombres germent avec une plus grande probabilité que les haricots.